

## RECURSO COMPLEMENTARIO

## Fundamentos de Transformers

Nota técnica 01

## El problema de modelar secuencias

Curso abierto

2026-I

*Modelar una secuencia autoregresivamente significa estimar, en cada posición, una distribución sobre el siguiente símbolo usando solo el pasado disponible.*

## 1 El problema estadístico

Un texto digitalizado puede representarse como una secuencia finita de símbolos discretos. Después de tokenizar, cada símbolo pertenece a un vocabulario finito  $\mathcal{V}$ . El problema de modelado no consiste en producir “una frase” como una etiqueta indivisible, sino en asignar probabilidades a continuaciones posibles de una historia parcial.

La unidad formal es una posición. Para cada  $t$ , el modelo observa un prefijo  $x_{<t}$  y debe estimar una distribución condicional sobre el siguiente token. Esta decisión local se repite a lo largo de la secuencia y, al encadenarse, define una distribución sobre secuencias completas.

**Idea clave 1 (Autoregresión).** La restricción autoregresiva no es una técnica de implementación: es una hipótesis de factorización. La secuencia completa se modela como producto de distribuciones condicionales locales, cada una condicionada solo en información anterior.

### Ampliación conceptual

La formulación autoregresiva debe entenderse como una forma de distribuir la dificultad. En lugar de modelar directamente todas las secuencias posibles como objetos completos, se modela una cadena de decisiones condicionales. Esto permite que una arquitectura produzca, en cada posición, un vector de puntajes sobre un vocabulario finito. La complejidad no desaparece: se traslada a la calidad de las representaciones internas que permiten estimar cada distribución local.

Un punto sutil es que la palabra "local" no significa necesariamente "simple". El factor  $p_{\theta}(x_t \mid x_{<t})$  puede depender de un contexto largo y de transformaciones profundas. Lo local es la decisión evaluada: el token actual. La información usada puede resumir muchas posiciones previas, siempre que no incluya futuro.

La diferencia entre distribución y decisión también es central. Durante entrenamiento interesa la distribución completa porque la pérdida compara la probabilidad asignada al token observado. Durante generación, en cambio, se necesita una regla para convertir esa distribución en un token concreto. Esa regla puede ser determinista o aleatoria, y por eso dos modelos con los mismos logits pueden producir textos distintos si usan estrategias de muestreo diferentes.

## 2 Secuencias, vocabulario y variables

Sea  $\mathcal{V}$  un vocabulario finito con cardinalidad  $|\mathcal{V}| = V$ . Una secuencia discreta de longitud  $T$  se escribe como

$$x_{1:T} = (x_1, x_2, \dots, x_T), \quad x_t \in \mathcal{V}.$$

El subíndice  $t$  identifica una posición temporal dentro de la secuencia, no un valor semántico del token. Dos tokens iguales pueden aparecer en posiciones distintas; dos posiciones distintas pueden contener el mismo símbolo.

El prefijo disponible antes de la posición  $t$  se denota

$$x_{<t} = (x_1, \dots, x_{t-1}).$$

Esta ecuación se lee así: para predecir la posición  $t$ , el contexto permitido contiene todos los tokens anteriores y excluye el token actual y cualquier token futuro.

## 3 Factorización autoregresiva

La regla de la cadena de probabilidad permite escribir

$$p(x_{1:T}) = \prod_{t=1}^T p(x_t \mid x_{<t}).$$

Esta ecuación se lee así: la probabilidad de una secuencia completa se obtiene multiplicando probabilidades condicionales, una por cada posición. Cada factor pregunta: dado el pasado disponible, ¿qué probabilidad recibe el token observado en la posición actual?

Un modelo parametrizado por  $\theta$  aproxima estos factores:

$$p_\theta(x_{1:T}) = \prod_{t=1}^T p_\theta(x_t \mid x_{<t}).$$

La diferencia entre  $p$  y  $p_\theta$  es importante.  $p$  representa la distribución desconocida que habría generado los datos;  $p_\theta$  es la distribución aprendida por una arquitectura concreta, con parámetros finitos, corpus limitado y longitud máxima de contexto.

## 4 Logits, softmax y distribución local

En una posición  $t$ , el modelo no produce directamente una palabra ni una probabilidad aislada. Produce un vector de puntajes no normalizados, llamados logits:

$$z_t = f_\theta(x_{<t}) \in \mathbb{R}^V.$$

Esta ecuación se lee así: a partir del contexto permitido, el modelo calcula un puntaje real para cada token del vocabulario.

Para convertir esos puntajes en una distribución categórica se aplica softmax:

$$p_\theta(x_t = j \mid x_{<t}) = \frac{\exp(z_{t,j})}{\sum_{k=1}^V \exp(z_{t,k})}, \quad j \in \{1, \dots, V\}.$$

Esta ecuación se lee así: el logit del token  $j$  se exponentia y se normaliza contra los logits de todo el vocabulario. El resultado es no negativo y las probabilidades de todos los tokens suman uno.

Otra limitación es que la factorización por sí sola no define una arquitectura. Un bigrama, una red recurrente y un Transformer pueden implementar el mismo objetivo autoregresivo con capacidades muy distintas. Por tanto, la ecuación fija el problema estadístico, pero no determina cuánta memoria, abstracción o composición puede aprender el sistema.

**Observación 1 (Logit no es probabilidad).** Un logit puede ser negativo, positivo o cero; no tiene por sí solo interpretación probabilística. Solo después de softmax se obtiene una distribución. El token observado  $x_t$  tampoco es una distribución: es el índice contra el cual se evalúa la predicción.

## 5 Pérdida de entrenamiento

Durante entrenamiento, el texto ya contiene el token observado. Por tanto, no se muestrea el siguiente token; se mide cuánta probabilidad asignó el modelo al token que realmente apareció. La pérdida usual por posición es la entropía cruzada negativa:

$$\ell_t(\theta) = -\log p_\theta(x_t \mid x_{<t}).$$

Esta ecuación se lee así: si el modelo asigna alta probabilidad al token observado, la penalización es pequeña; si le asigna baja probabilidad, la penalización crece.

Para una secuencia completa se promedia la pérdida sobre posiciones:

$$\mathcal{L}(\theta) = -\frac{1}{T} \sum_{t=1}^T \log p_\theta(x_t \mid x_{<t}).$$

En entrenamiento con batches, esta suma se extiende a ejemplos  $b = 1, \dots, B$ :

$$\mathcal{L}(\theta) = -\frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T \log p_\theta(x_{b,t} \mid x_{b,<t}).$$

Esta forma explica por qué los logits de un modelo de lenguaje suelen tener forma  $(B, T, V)$ : para cada ejemplo del batch y cada posición temporal se produce un vector de puntajes sobre el vocabulario.

## 6 Entrenamiento y generación

La misma factorización sostiene dos procedimientos distintos. En entrenamiento se conoce  $x_t$  y se ajustan los parámetros  $\theta$  para aumentar su probabilidad promedio. En generación se toma un contexto inicial, se calcula  $p_\theta(\cdot \mid x_{<t})$ , se elige o muestrea un token nuevo  $\hat{x}_t$ , y ese token se agrega al contexto:

$$x_{<t} \rightarrow p_\theta(\cdot \mid x_{<t}) \rightarrow \hat{x}_t \rightarrow (x_{<t}, \hat{x}_t).$$

Esta cadena se lee así: generar texto es iterar una distribución local; no es producir una secuencia completa en una sola operación.

## 7 Lectura tensorial y restricción causal

Una secuencia codificada puede verse como un tensor de índices con forma  $(T, )$ . Un batch de secuencias se representa como

$$X \in \mathbb{N}^{B \times T}.$$


El modelo transforma esos índices en representaciones internas y finalmente en logits:

$$Z \in \mathbb{R}^{B \times T \times V}.$$

La dimensión  $B$  agrupa ejemplos,  $T$  recorre posiciones y  $V$  recorre tokens candidatos.

La causalidad no está garantizada por la forma del tensor. Un tensor  $(B, T, V)$  puede contener predicciones válidas o filtradas con fuga de futuro. La restricción causal exige que la representación usada en la posición  $t$  no dependa de  $x_{>t}$ . En arquitecturas con atención, esta restricción se implementa mediante una máscara triangular; conceptualmente, se impone antes: el futuro no es información disponible para predecir el presente.

## 8 Figura conceptual



La figura ilustra la frontera causal móvil. Para una posición dada, el contexto permitido está a la izquierda; el token que se evalúa está en la frontera; el futuro queda excluido. Esta separación es la condición que hace coherente la pérdida autoregresiva y evita que el modelo resuelva la tarea mirando la respuesta.

### Cómo leer la figura

La frontera vertical de la figura debe leerse como una condición de información, no como una marca gráfica. Todo lo que queda a la izquierda puede influir en la predicción; todo lo que queda a la derecha debe permanecer oculto. En implementaciones reales, esta regla se materializa en la preparación de targets y en la máscara causal de atención.

También conviene distinguir el token observado del token elegido. En entrenamiento, el token en la frontera ya existe en el corpus y sirve para calcular pérdida. En generación, el token en esa frontera será producido por el modelo y luego pasará a formar parte del contexto. La misma factorización sostiene ambos procesos, pero la operación práctica cambia.

## 9 Límites de interpretación

La factorización autoregresiva define una tarea estadística, no una teoría completa de comprensión. Un modelo puede reducir  $\mathcal{L}(\theta)$  y aun así fallar en coherencia larga, seguimiento de instrucciones, factualidad o consistencia narrativa. La pérdida local evalúa probabilidad promedio de tokens observados bajo una configuración de datos, arquitectura y contexto; no mide por sí sola entendimiento semántico general.

**Observación 2 (Cautela).** Una menor entropía cruzada indica que el modelo asigna más probabilidad promedio a los tokens observados. No implica que haya aprendido causas, hechos del mundo o una representación estable de significado.

## 10 Resumen

**Resumen 1 (Cierre de la nota).** El modelado autoregresivo convierte una secuencia discreta en una familia de predicciones locales. Cada posición produce logits sobre el vocabulario, softmax los transforma en una distribución, la entropía cruzada penaliza baja probabilidad sobre el token observado y la restricción causal impide usar información futura. Esta base será reutilizada por embeddings, atención, bloques decoder, entrenamiento y generación.

## 11 Preguntas de estudio

1. ¿Qué hipótesis introduce la factorización  $p_\theta(x_{1:T}) = \prod_t p_\theta(x_t | x_{<t})$ ?
2. ¿Por qué un vector de logits  $z_t \in \mathbb{R}^V$  no puede interpretarse directamente como una distribución?
3. ¿Cómo se relaciona la forma  $(B, T, V)$  de los logits con la pérdida de entropía cruzada?
4. ¿Qué error metodológico aparece si la predicción en la posición  $t$  puede depender de  $x_{>t}$ ?
5. ¿Por qué una pérdida menor no basta para afirmar comprensión lingüística general?

## 12 Continuidad

El siguiente paso técnico es construir los objetos discretos que hacen calculable esta formulación: tokens, vocabulario, índices, ventanas de contexto y pares entrada–objetivo.