

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 03

Embeddings y geometría de tokens

Curso abierto

2026-I

Un embedding no es el significado de un token: es una fila entrenable que el modelo aprende a usar dentro de una tarea.

1 De índices a vectores

Los índices discretos permiten nombrar tokens, pero no contienen una representación numérica útil para operaciones lineales. Una capa de embeddings introduce una tabla de parámetros

$$E \in \mathbb{R}^{V \times C},$$

donde V es el tamaño del vocabulario y C es la dimensión del embedding. Cada fila de E corresponde a un token del vocabulario.

Si $x_t \in \{0, \dots, V-1\}$ es el índice de un token, su embedding se obtiene por consulta de fila:

$$z_t = E[x_t] \in \mathbb{R}^C.$$

Esta ecuación se lee así: el índice no se multiplica como número; se usa como llave para seleccionar una fila entrenable.

Idea clave 1 (Lookup). La operación central de embeddings es un lookup. El índice decide qué fila se lee; la fila contiene parámetros que se ajustan con gradiente cuando esa fila participa en la pérdida.

Ampliación conceptual

La tabla de embeddings introduce el primer objeto continuo del modelo. Antes de ella, el sistema solo manipula enteros; después de ella, cada token queda asociado a un vector que puede sumarse, proyectarse y recibir gradiente. Esta transición es importante porque las capas lineales y la atención operan sobre vectores, no sobre símbolos discretos.

El lookup puede parecer una operación simple, pero tiene una consecuencia estadística fuerte: todos los usos de un mismo token comparten la misma fila inicial. Por ejemplo, si el índice i aparece en muchas posiciones y contextos, todas esas apariciones consultan E_i . La fila se va ajustando por la acumulación de señales provenientes de todos esos usos.

La dimensión C no debe interpretarse como número de rasgos nombrables. No hay garantía de que un canal corresponda a plural, género, tema o función sintáctica. Los canales son coordenadas aprendidas en un espacio útil para minimizar la pérdida. Algunas direcciones pueden volverse interpretables, pero esa interpretación requiere evidencia posterior.

2 Forma tensorial

Para un batch de índices

$$X \in \mathbb{N}^{B \times T},$$

la consulta de embeddings produce

$$Z = E[X] \in \mathbb{R}^{B \times T \times C}.$$

Esta ecuación se lee así: cada posición discreta del batch se reemplaza por un vector de C componentes. Los ejes B y T se conservan; aparece un nuevo eje de canales continuos.

El número de parámetros de la tabla es

$$\#E = V \cdot C.$$

Aumentar C amplía la capacidad representacional, pero también aumenta parámetros, memoria y riesgo de ajuste pobre en datos pequeños.

3 Gradiente y filas actualizadas

Durante retropropagación, no todas las filas de E reciben señal en cada batch. Si una pérdida depende de los embeddings consultados por los índices de X , las filas candidatas a actualizar son

$$\{x_{b,t} : 1 \leq b \leq B, 1 \leq t \leq T\}.$$

Esta expresión se lee así: solo los tokens que aparecen en el batch participan directamente en esa actualización. Tokens ausentes no reciben gradiente en esa iteración.

La actualización idealizada para una fila i puede escribirse como

$$E_i \leftarrow E_i - \eta \frac{\partial \mathcal{L}}{\partial E_i},$$

donde η es la tasa de aprendizaje. La geometría de embeddings es, por tanto, resultado de muchas actualizaciones guiadas por la tarea.

4 Geometría aprendida


Como $E_i \in \mathbb{R}^C$, es tentador interpretar distancias o direcciones como significado. Esa interpretación solo es razonable después de entrenamiento suficiente y siempre dentro de una tarea concreta. Una tabla inicial aleatoria tiene coordenadas, pero no una semántica estable.

La similitud coseno entre dos embeddings entrenados se define como

$$\cos(E_i, E_j) = \frac{E_i^\top E_j}{\|E_i\| \|E_j\|}.$$

Esta ecuación mide alineación geométrica, no equivalencia lingüística. Dos tokens pueden acercarse porque cumplen funciones parecidas en el corpus, no porque tengan el mismo significado fuera del modelo.

5 Figura conceptual



La figura debe leerse como una tabla de consulta: los índices entran como llaves y salen vectores. La visualización bidimensional es útil para intuir coordenadas, pero no debe confundirse con evidencia semántica.

Cómo leer la figura

La figura muestra una tabla, no un diccionario semántico. Las filas son parámetros y las columnas son coordenadas. Cuando un índice entra, selecciona una fila completa. Si varios índices entran en un batch, se consultan varias filas y se forma un tensor con un vector por posición.

Si aparece una representación bidimensional, debe leerse como apoyo visual para entender coordenadas. En dimensiones reales mayores, la geometría no se ve directamente; se analiza mediante distancias, productos punto, proyecciones o comportamiento en la tarea.

6 Límites de interpretación

Los embeddings no son definiciones de diccionario ni conocimiento externo. Son parámetros útiles para minimizar una pérdida. Su geometría depende de corpus, arquitectura, inicialización, dimensión, tokenización y objetivo de entrenamiento.

La geometría de embeddings también depende de la frecuencia. Tokens raros reciben menos actualizaciones y pueden quedar peor ubicados. Tokens frecuentes reciben más señal, pero esa señal puede mezclar muchos usos distintos. Por eso la interpretación de una fila aislada siempre debe hacerse dentro del corpus y del entrenamiento que la produjo.

Observación 1 (Geometría inicial). Una nube de puntos generada con embeddings sin entrenar solo muestra números aleatorios organizados en una tabla. La estructura interpretativa aparece, si aparece, después del aprendizaje.

7 Resumen

Resumen 1 (Cierre de la nota). Una capa de embeddings transforma índices (B, T) en vectores (B, T, C) mediante consulta de filas en una tabla entrenable. La dimensión C controla capacidad y costo; las filas se actualizan cuando participan en la pérdida; la geometría resultante debe interpretarse con cautela.

8 Preguntas de estudio

1. ¿Por qué el índice de un token funciona como llave y no como valor numérico continuo?
2. ¿Qué significa que E tenga forma $V \times C$?
3. ¿Qué filas de E reciben gradiente en un batch dado?
4. ¿Por qué aumentar C aumenta parámetros y capacidad?
5. ¿Por qué una visualización 2D inicial no prueba significado semántico?

9 Continuidad

Los embeddings de token aportan contenido, pero no posición. Para representar secuencias, el modelo también necesita información explícita de orden.