

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 04

Posición y orden en secuencias

Curso abierto

2026-I

Una secuencia no queda definida solo por sus tokens: también importa dónde aparece cada token.

1 Contenido y orden

Una tabla de embeddings asigna un vector a cada token, pero el mismo token recibe la misma fila aunque aparezca al inicio, en el medio o al final. Si una arquitectura mezcla posiciones sin una señal adicional de orden, dos secuencias con los mismos tokens podrían volverse indistinguibles para ciertas operaciones.

La representación de una posición debe combinar dos fuentes: contenido y lugar. El contenido responde qué token aparece; la posición responde dónde aparece.

Idea clave 1 (Orden). El orden no está contenido en el índice del token. Debe incorporarse mediante una señal posicional compatible con la dimensión del embedding de token.

Ampliación conceptual

El orden es una propiedad relacional. La secuencia "modelo aprende" no expresa lo mismo que "aprende modelo", aunque contenga los mismos tokens. Si una arquitectura no recibe ninguna señal de posición, debe inferir orden únicamente por la estructura de sus operaciones. En self-attention pura, las comparaciones entre tokens no bastan para distinguir de forma natural cuál apareció primero.

La suma de embedding de token y embedding posicional es una solución práctica porque ambos viven en el mismo espacio de canales. No se agrega un eje nuevo; se modifica el vector inicial de cada posición. Así, el token "modelo" en la posición 0 y el mismo token en la posición 5 comparten componente de contenido, pero difieren por la componente posicional.

Las posiciones absolutas aprendidas funcionan bien dentro del rango entrenado. Su debilidad es que cada fila corresponde a una posición específica. Si se pide extrapolar más allá de la longitud máxima, no hay una fila aprendida que represente esa nueva posición.

2 Embeddings posicionales aprendidos

Sea una ventana de longitud máxima $T_{\text{máx}}$. Una tabla posicional aprendida se define como

$$P \in \mathbb{R}^{T_{\text{máx}} \times C}.$$

Cada fila P_t representa una posición absoluta. Si $E \in \mathbb{R}^{V \times C}$ es la tabla de tokens, la representación combinada en la posición t es

$$h_t = E[x_t] + P_t \in \mathbb{R}^C.$$

Esta ecuación se lee así: el vector de contenido y el vector de posición tienen la misma dimensión, por eso pueden sumarse componente a componente.

Para un batch,

$$H_{b,t,:} = E[x_{b,t}] + P_t,$$

y el resultado tiene forma

$$H \in \mathbb{R}^{B \times T \times C}.$$

La posición se comparte entre ejemplos del batch: la fila P_t se usa para toda secuencia en la posición t .

3 Compatibilidad dimensional


La suma $E[x_t] + P_t$ solo está definida si ambos vectores viven en $\mathbb{R}^C$. Esto fija una interfaz: todo lo que entra al bloque Transformer debe conservar la dimensión de canales C . La tabla posicional no cambia el número de tokens ni el tamaño del vocabulario; cambia la representación inicial de cada posición.

Si se intenta usar una posición $t \geq T_{\text{máx}}$, no existe fila aprendida P_t . Por eso los embeddings posicionales aprendidos imponen una longitud máxima explícita.

4 Otras señales posicionales

Las posiciones aprendidas no son la única alternativa. También existen codificaciones sinusoidales, relativas y rotatorias. Todas responden al mismo problema: hacer que la arquitectura pueda distinguir orden. La diferencia está en cómo extrapolan, qué sesgo inducen y cómo interactúan con atención.

5 Figura conceptual



La figura ilustra la suma de dos tablas compatibles: una indexada por token y otra indexada por posición. La representación inicial de una secuencia surge de esa suma, no de una concatenación ni de una etiqueta externa.

Cómo leer la figura

La figura debe leerse como una suma de dos fuentes de información. La tabla de tokens responde qué símbolo aparece; la tabla posicional responde dónde aparece. La representación combinada es el punto de partida para atención y MLP.

No debe interpretarse que la posición domine al token o que el token domine a la posición. Ambas señales quedan mezcladas en el mismo vector y las capas posteriores aprenderán a usar esa mezcla según la tarea.

6 Límites de interpretación

Una posición absoluta aprendida indica lugar dentro de una ventana, no función gramatical ni importancia. Además, aprender filas posicionales en contextos cortos no garantiza extrapolación a secuencias más largas.

Una señal posicional indica orden, pero no entiende estructura. Saber que un token está en la posición 3 no dice si es sujeto, verbo o complemento. Esas relaciones, si se aprenden, emergen de la interacción entre posición, contenido, atención, datos y pérdida.

Observación 1 (Longitud máxima). El límite de contexto no es solo una decisión de memoria. Con posiciones aprendidas, también es un límite de la tabla posicional disponible.

7 Resumen

Resumen 1 (Cierre de la nota). Los embeddings de token aportan contenido y los embeddings posicionales aportan orden. La suma $E[x_t] + P_t$ produce una representación compatible con la interfaz (B, T, C) . Sin señal posicional, el modelo pierde una parte esencial de la estructura secuencial.

8 Preguntas de estudio

1. ¿Por qué el mismo token necesita representaciones distintas según su posición?
2. ¿Qué condición dimensional permite sumar token embedding y positional embedding?
3. ¿Qué ocurre si una secuencia excede $T_{\text{máx}}$ con posiciones aprendidas?
4. ¿Qué diferencia hay entre contenido del token y posición en la secuencia?
5. ¿Por qué una señal posicional no equivale a entender sintaxis?

9 Continuidad

Con contenido y posición representados en (B, T, C) , el siguiente problema es manipular tensores con ejes claros antes de construir atención.