

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 05

Tensores del Transformer

Curso abierto

2026-I

Entender Transformers exige leer qué significa cada eje antes de leer cualquier operación.

1 Alfabetización tensorial

La arquitectura Transformer se expresa como una cadena de transformaciones sobre tensores. La mayoría de errores conceptuales aparecen cuando se confunden ejes: batch, tiempo, canales, cabezas o dimensión por cabeza. Por eso conviene fijar una notación común.

Usaremos

$$X \in \mathbb{R}^{B \times T \times C},$$

donde B es batch, T es longitud de contexto y C es dimensión de canales o embedding.

Idea clave 1 (Ejes). Un reshape no debe interpretarse solo como reordenamiento técnico. Cambiar la forma cambia qué agrupaciones de números se consideran ejemplos, posiciones, canales o cabezas.

Ampliación conceptual

La notación tensorial es una forma de controlar el significado del cómputo. El eje B permite procesar varios ejemplos con los mismos parámetros; el eje T conserva la estructura secuencial; el eje C contiene características continuas de cada posición. Confundir estos ejes puede producir código que ejecuta pero implementa otro modelo.

Las proyecciones lineales por posición son compartidas a lo largo de B y T . Esto significa que la misma matriz se aplica a cada vector de canales. El modelo no aprende una matriz distinta para cada posición; aprende transformaciones reutilizables que operan sobre representaciones.

La división en cabezas introduce una lectura adicional del eje de canales. Pasar de (B, T, C) a (B, H, T, D) no crea más información; reorganiza la existente para calcular varias atenciones en paralelo. La recombinación posterior vuelve a reunir esos subespacios.

2 Proyecciones lineales

Una proyección lineal aplicada por posición se escribe como

$$Y = XW + b, \quad W \in \mathbb{R}^{C \times C'}.$$

Esta ecuación se lee así: cada vector de canales en una posición se transforma mediante la misma matriz W . Los ejes B y T se conservan; el eje de canales pasa de C a C' .

Para atención, estas proyecciones producen consultas, llaves y valores. Incluso antes de definir atención, la forma indica que cada posición obtiene vectores derivados de su representación.

3 Cabezas y divisibilidad

En multi-head attention se divide el eje de canales en H cabezas. Si D es la dimensión por cabeza, debe cumplirse

$$C = H \cdot D.$$

Esta ecuación se lee así: los canales totales se reparten en H grupos del mismo tamaño. Si C no es divisible por H , no se puede formar una partición regular sin perder o rellenar canales.

La reorganización típica es

$$(B, T, C) \rightarrow (B, T, H, D) \rightarrow (B, H, T, D).$$

La primera forma separa canales por cabeza; la segunda pone el eje de cabezas antes del tiempo para calcular atención en paralelo por cabeza.

4 Contigüidad e interpretación

Operaciones como view, reshape o transposición no son equivalentes en todos los casos. Una transposición cambia el orden lógico de lectura de los datos; una vista requiere que la memoria permita interpretar el mismo bloque con otra forma. Conceptualmente, lo importante es que la operación preserve el significado de los ejes.

5 Figura conceptual



La figura resume cómo una representación (B, T, C) puede proyectarse, dividirse en cabezas y reorganizarse para atención. La lectura correcta empieza por los ejes, no por la sintaxis de PyTorch.

Cómo leer la figura

La figura puede leerse como un mapa de conservación y transformación de ejes. Algunas operaciones conservan B y T , otras separan C en H y D , y otras reordenan ejes para facilitar multiplicaciones matriciales.

Cuando se vea una forma tensorial, conviene preguntarse: qué representa cada eje, qué operación lo creó, qué operación lo consumirá y si la forma coincide con la intención matemática.

6 Límites de interpretación

Una forma tensorial válida no garantiza una operación semánticamente correcta. Es posible obtener dimensiones compatibles y aun así mezclar ejes incorrectos. La verificación debe incluir forma, significado de ejes y relación con la ecuación matemática.

La depuración por forma es necesaria pero insuficiente. Un tensor con forma correcta puede tener ejes permutados de manera equivocada o valores calculados con una máscara incorrecta. Por eso la auditoría debe combinar forma, nombres de ejes y pruebas de comportamiento.

Observación 1 (Compatibilidad). Que dos tensores puedan multiplicarse no significa que deban multiplicarse. La compatibilidad algebraica debe coincidir con la intención del modelo.

7 Resumen

Resumen 1 (Cierre de la nota). Los Transformers manipulan tensores con ejes bien definidos. B agrupa ejemplos, T ordena posiciones, C contiene canales, H separa cabezas y D define canales por cabeza. La condición $C = H \cdot D$ permite dividir y recombinar representaciones.

8 Preguntas de estudio

1. ¿Qué representa cada eje en (B, T, C) ?
2. ¿Por qué una proyección lineal conserva B y T ?
3. ¿Qué falla si C no es divisible por H ?
4. ¿Por qué transponer un tensor puede cambiar su interpretación?
5. ¿Qué diferencia hay entre una forma válida y una operación conceptualmente correcta?

9 Continuidad

Con los ejes definidos, se puede estudiar atención como una mezcla ponderada de valores guiada por pesos normalizados.