

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 06

Atención como mezcla ponderada

Curso abierto

2026-I

Atender es construir una salida como mezcla ponderada de valores disponibles.

1 Mezcla de información

La atención puede introducirse sin consultas ni llaves: como una operación que toma varios vectores de valor y produce una combinación ponderada. Si hay T valores

$$v_1, \dots, v_T \in \mathbb{R}^D,$$

y pesos $\alpha_1, \dots, \alpha_T$, la salida es

$$y = \sum_{j=1}^T \alpha_j v_j.$$

Esta ecuación se lee así: cada valor aporta a la salida según un peso escalar.

Para que la mezcla sea una distribución de pesos, se exige

$$\alpha_j \geq 0, \quad \sum_{j=1}^T \alpha_j = 1.$$

Así, y queda dentro de la envolvente convexa de los valores cuando los pesos son estrictamente probabilísticos.

Idea clave 1 (Pesos). La atención no selecciona necesariamente un solo elemento. Puede distribuir masa entre varias posiciones y producir una representación nueva que combina información.

Ampliación conceptual

La mezcla ponderada es una operación de agregación. Su propósito no es copiar un valor necesariamente, sino construir una representación nueva a partir de varios valores disponibles. Si un peso domina, la salida se parece mucho a un valor particular; si los pesos se distribuyen, la salida combina varias fuentes.

Softmax introduce competencia entre posiciones. Aumentar un logit no solo aumenta su peso; también reduce proporcionalmente la masa disponible para los demás. Esta propiedad hace que la atención pueda concentrarse o dispersarse según la escala relativa de los scores.

La interpretación geométrica también importa. Si los valores son vectores en $\mathbb{R}^D$, la salida vive en el mismo espacio. Por tanto, atención cambia el contenido de una posición sin cambiar la dimensión de representación.

2 De logits a pesos

Los pesos suelen obtenerse a partir de logits $s_j \in \mathbb{R}$. Softmax transforma esos puntajes en pesos normalizados:

$$\alpha_j = \frac{\exp(s_j)}{\sum_{k=1}^T \exp(s_k)}.$$

Esta ecuación se lee así: cada puntaje compite con todos los demás; subir un logit aumenta su peso relativo y puede reducir la masa asignada a otros valores.

La salida completa queda entonces

$$y = \sum_{j=1}^T \frac{\exp(s_j)}{\sum_{k=1}^T \exp(s_k)} v_j.$$

Esta expresión separa claramente dos objetos: los logits deciden cuánto pesa cada posición; los valores contienen lo que se mezcla.

3 Forma matricial mínima

Si los valores se organizan como una matriz


$$V \in \mathbb{R}^{T \times D},$$

y los pesos como un vector fila $\alpha \in \mathbb{R}^{1 \times T}$, entonces

$$y = \alpha V \in \mathbb{R}^{1 \times D}.$$

Con varias consultas, se apilan varios vectores de pesos en una matriz $A \in \mathbb{R}^{T \times T}$ y la salida se escribe como $Y = AV$.

4 Figura conceptual



La figura ilustra que la salida no sale de un único valor, sino de aportes ponderados. La interpretación correcta debe mirar simultáneamente pesos y valores.

Cómo leer la figura

La figura debe leerse como una balanza de aportes. Los pesos indican cuánto contribuye cada value, pero el contenido final depende también de qué contienen esos values. Dos valores muy distintos pueden recibir pesos parecidos y producir una salida intermedia.

La flecha hacia la salida representa una suma ponderada. No es una selección dura salvo en el caso límite en que casi toda la masa cae sobre una sola posición.

5 Límites de interpretación

Un peso alto indica contribución numérica en esa operación, no una explicación causal completa del comportamiento del modelo. Si el valor asociado contiene información pobre o mezclada, un peso alto no garantiza una interpretación semántica limpia.

Un peso bajo tampoco significa irrelevancia absoluta. En redes profundas, pequeñas contribuciones pueden acumularse o interactuar con capas posteriores. La atención visible es una parte del circuito, no el circuito completo.

Observación 1 (Atención visible). Los pesos de atención son objetos intermedios. Pueden ayudar a diagnosticar una mezcla, pero no sustituyen análisis de datos, arquitectura, entrenamiento y salida final.

6 Resumen

Resumen 1 (Cierre de la nota). La atención puede entenderse como una mezcla ponderada: logits producen pesos mediante softmax y los pesos combinan valores. Esta base permite luego introducir consultas y llaves como mecanismo para calcular los logits.

7 Preguntas de estudio

1. ¿Por qué los pesos de atención suelen normalizarse con softmax?
2. ¿Qué diferencia hay entre logit, peso y valor?
3. ¿Qué significa que los pesos sumen uno?
4. ¿Por qué un peso alto no prueba una explicación semántica completa?
5. ¿Cómo se expresa una mezcla ponderada en forma matricial?

8 Continuidad

Para calcular los logits de forma dependiente del contenido se introducen consultas, llaves y valores.