

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 07

Queries, Keys y Values

Curso abierto

2026-I

Queries, keys y values separan tres funciones: preguntar, ser comparable y aportar contenido.

1 Tres proyecciones con roles distintos

En atención, cada posición genera tres vectores a partir de su representación: query, key y value. Para una entrada $x_i \in \mathbb{R}^C$, se definen

$$q_i = x_i W_Q, \quad k_i = x_i W_K, \quad v_i = x_i W_V.$$

Esta ecuación se lee así: la misma posición se proyecta en tres espacios funcionales. La query se usa para consultar, la key para ser comparada y el value para aportar contenido a la mezcla.

Idea clave 1 (Separación de roles). La atención no compara directamente los valores que mezcla. Compara queries con keys para decidir pesos, y luego aplica esos pesos sobre values.

Ampliación conceptual

Separar Q , K y V permite que una posición tenga distintas representaciones según la función que cumple. La misma información de entrada puede transformarse en una query útil para buscar, una key útil para ser encontrada y un value útil para aportar contenido.

El producto punto $q_i^\top k_j$ mide alineación en el espacio de comparación. Si ambos vectores apuntan en direcciones similares, el score tiende a ser alto. Sin embargo, esa alineación es aprendida: no corresponde necesariamente a similitud léxica visible.

La división por $\sqrt{D}$ evita que los productos punto crezcan demasiado con la dimensión. Si los scores tienen magnitudes muy grandes, softmax puede saturarse y producir distribuciones casi deterministas, lo que dificulta gradientes útiles.

2 Score de compatibilidad

Para saber cuánto debe atender la posición i a la posición j , se calcula

$$s_{ij} = \frac{q_i^\top k_j}{\sqrt{D}}.$$

Esta ecuación se lee así: la consulta de la posición i se compara con la llave de la posición j . El factor $\sqrt{D}$ estabiliza la escala de los productos punto cuando la dimensión crece.

Los scores de una query se normalizan por fila:

$$\alpha_{ij} = \frac{\exp(s_{ij})}{\sum_{m=1}^T \exp(s_{im})}.$$

Así, para cada i , los pesos α_{ij} forman una distribución sobre posiciones consultadas.

3 Mezcla de valores


La salida de la posición i es

$$y_i = \sum_{j=1}^T \alpha_{ij} v_j.$$

Esta ecuación se lee así: la posición i recibe una mezcla de contenidos v_j , ponderada por la compatibilidad entre su query y las keys disponibles.

La distinción entre K y V es crucial: una posición puede ser útil para decidir dónde mirar y, al mismo tiempo, aportar otro tipo de contenido cuando se mezcla.

4 Figura conceptual



La figura separa comparación y contenido. Las flechas de score pertenecen al espacio query-key; la mezcla final pertenece al espacio de valores.

Cómo leer la figura

La figura ayuda a no confundir los caminos. El camino query-key produce pesos. El camino value aporta los vectores que serán mezclados. Aunque ambos nacen de la misma entrada, cumplen funciones distintas.

Una lectura útil es seguir una posición específica: su query compara contra todas las keys; esa comparación genera una fila de pesos; esa fila mezcla todos los valores permitidos.

5 Límites de interpretación

Aunque los nombres query, key y value son intuitivos, no deben leerse como lenguaje natural literal. Son proyecciones lineales entrenables. Su significado funcional emerge de la pérdida y de la arquitectura, no de una definición manual.

Las metáforas de pregunta, llave y valor sirven para recordar roles, pero no deben reemplazar la operación matemática. Los vectores no contienen preguntas en lenguaje natural; contienen coordenadas aprendidas que optimizan una tarea.

Observación 1 (Interpretación). Decir que una query pregunta y una key responde es una metáfora útil, pero la operación real es un producto punto escalado entre vectores aprendidos.

6 Errores de lectura técnica

Un error frecuente es creer que Q , K y V son tres copias equivalentes de la entrada. Aunque nacen de la misma representación, sus matrices de proyección son distintas y reciben gradientes según roles diferentes. Esto permite que el modelo aprenda un espacio para comparar y otro para transportar contenido.

Otro error es interpretar el score s_{ij} como una decisión final. El score es anterior a softmax y solo tiene sentido relativo frente a los demás scores de la misma fila. Una posición puede tener un score positivo y aun así recibir poco peso si otros scores son mucho mayores.

También conviene separar la dimensión D de la longitud T . D controla el tamaño de los vectores query/key/value; T controla cuántas posiciones se comparan. El producto punto ocurre en el eje de canales, pero la matriz de atención se organiza sobre posiciones.

7 Resumen

Resumen 1 (Cierre de la nota). Queries calculan compatibilidad, keys permiten ser comparadas y values aportan contenido. Los scores $q_i^\top k_j$ se normalizan por softmax y los pesos resultantes mezclan valores para producir una salida por posición.

8 Preguntas de estudio

1. ¿Por qué se usan tres proyecciones distintas en lugar de una sola?
2. ¿Qué representa el score s_{ij} ?
3. ¿Por qué se divide por $\sqrt{D}$?
4. ¿Qué diferencia funcional hay entre k_j y v_j ?
5. ¿Por qué una fila de pesos se interpreta como distribución sobre posiciones?

9 Continuidad

Al apilar queries, keys y values de todas las posiciones, se obtiene la forma matricial completa de self-attention.