

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 08

Self-attention matricial

Curso abierto

2026-I

Self-attention calcula, en paralelo, cómo cada posición mezcla información de todas las posiciones disponibles.

1 De una consulta a todas las consultas

La formulación con una query explica la operación local. La self-attention matricial calcula todas las consultas simultáneamente. Para una secuencia representada por

$$X \in \mathbb{R}^{T \times C},$$

se definen tres proyecciones

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

Esta ecuación se lee así: cada posición de la misma secuencia produce query, key y value. Por eso se llama self-attention: la secuencia se consulta a sí misma.

Idea clave 1 (Paralelismo). La forma matricial no cambia la idea de atención; la organiza para calcular todos los scores y todas las mezclas con operaciones vectorizadas.

Ampliación conceptual

La forma matricial muestra que self-attention no procesa cada posición como un bucle conceptual independiente, aunque esa sea una forma de entenderla. Al apilar todas las queries y todas las keys, el producto $QK^\top$ calcula de una vez todas las compatibilidades posición a posición.

Cada fila de S corresponde a una posición que consulta. Cada columna corresponde a una posición consultada. Esta convención es importante porque softmax se aplica por filas: se normalizan las alternativas disponibles para una misma query, no todos los scores de la matriz al mismo tiempo.

La salida $Y = AV$ conserva el número de posiciones porque cada fila de A produce una mezcla para una posición de salida. Lo que cambia es el contenido de cada vector: ya no representa solo información local de la posición, sino información agregada desde otras posiciones.

2 Scores y pesos

Si $Q, K \in \mathbb{R}^{T \times D}$, la matriz de scores es

$$S = \frac{QK^\top}{\sqrt{D}} \in \mathbb{R}^{T \times T}.$$

Esta ecuación se lee así: la fila i contiene la comparación de la query de la posición i contra todas las keys de la secuencia.

Los pesos de atención se obtienen normalizando cada fila:

$$A_{i,:} = \text{softmax}(S_{i,:}), \quad A \in \mathbb{R}^{T \times T}.$$

Cada fila de A suma uno y define una distribución sobre posiciones consultadas.

3 Salida matricial

La salida se obtiene como

$$Y = AV, \quad Y \in \mathbb{R}^{T \times D}.$$


Esta ecuación se lee así: cada fila de Y es una mezcla ponderada de las filas de V . El resultado vuelve a tener un vector por posición.

Con batch, las formas pasan a

$$Q, K, V \in \mathbb{R}^{B \times T \times D}, \quad S, A \in \mathbb{R}^{B \times T \times T}, \quad Y \in \mathbb{R}^{B \times T \times D}.$$

El eje B indica que la operación se repite independientemente para cada ejemplo.

4 Figura conceptual



La figura muestra la cadena $QK^\top$, normalización por filas y mezcla con V . Una celda A_{ij} indica cuánto aporta el value de la posición j a la salida de la posición i .

Cómo leer la figura

La figura debe leerse en tres momentos: primero se construyen Q , K y V ; luego $QK^\top$ produce scores y softmax los convierte en pesos; finalmente A mezcla V . Separar estos momentos evita confundir comparación con agregación.

El mapa de calor de A no debe verse como una tabla de significados. Es una tabla de pesos condicionada por parámetros, entrada y normalización.

5 Límites de interpretación

La matriz A es intermedia. No contiene texto, no contiene salida final y no es por sí sola una explicación causal. Además, si no se aplica máscara, una posición puede atender al futuro, lo cual viola el objetivo autoregresivo.

Otra limitación es el costo cuadrático. La matriz $T \times T$ crece rápidamente con la longitud de contexto. Esta propiedad explica por qué la atención estándar se vuelve costosa en secuencias largas.

Observación 1 (Sin causalidad). Self-attention sin máscara es válida para muchas tareas, pero no basta para generación autoregresiva. Para predecir el siguiente token debe impedirse mirar posiciones futuras.

6 Errores de lectura técnica

Una confusión común es pensar que $QK^\top$ mezcla valores. No los mezcla: solo calcula compatibilidades. La mezcla aparece después, cuando A multiplica a V . Esta separación es importante para depurar implementaciones: si los scores parecen razonables pero la salida no, el problema puede estar en la normalización o en los valores.

Otra confusión es normalizar por columnas. En la convención usual, cada fila corresponde a una posición que consulta; por eso softmax se aplica por filas. Normalizar por columnas respondería otra pregunta: qué posiciones consultan a una misma key. Esa puede ser una estadística interesante, pero no es la distribución usada para construir cada salida.

Finalmente, la forma (B, T, T) de A no debe confundirse con (B, T, D) . La matriz de atención vive en el espacio de posiciones; la salida vive en el espacio de canales. La multiplicación AV es precisamente el puente entre ambos.

7 Resumen

Resumen 1 (Cierre de la nota). La self-attention matricial calcula Q , K , V , scores S , pesos A y salidas Y para todas las posiciones en paralelo. La normalización por filas convierte cada fila de scores en una distribución sobre posiciones.

8 Preguntas de estudio

1. ¿Por qué S tiene forma $T \times T$?
2. ¿Qué representa una fila de A ?
3. ¿Por qué Y vuelve a tener una fila por posición?
4. ¿Qué cambia al introducir el eje de batch?
5. ¿Por qué esta operación todavía no garantiza causalidad?

9 Continuidad

Para hacer compatible self-attention con generación autoregresiva se introduce una máscara causal triangular.