

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 09

Atención causal

Curso abierto

2026-I

La máscara causal convierte self-attention en una operación compatible con predicción autoregresiva.

1 Fuga de futuro

En self-attention sin restricciones, la posición i puede asignar peso a cualquier posición j . En modelado autoregresivo esto es inválido: al predecir una posición, el futuro no debe estar disponible. Si $j > i$, la posición j contiene información posterior.

La atención causal impone una restricción estructural: cada fila solo puede consultar posiciones anteriores o la posición actual.

Idea clave 1 (Causalidad). La máscara causal no mejora la arquitectura por sí misma; evita una trampa metodológica. Sin ella, el modelo podría usar información futura y obtener una pérdida artificialmente baja.

Ampliación conceptual

La máscara causal transforma una operación simétrica en una operación dirigida por el tiempo. Sin máscara, la posición 2 puede mirar la posición 8 igual que la posición 8 puede mirar la posición 2. Con máscara causal, esa relación deja de ser simétrica: el pasado puede influir en el futuro, pero el futuro no puede influir en el pasado.

El uso de $-\infty$ antes de softmax tiene una razón matemática: $\exp(-\infty) = 0$. Así, las posiciones prohibidas reciben probabilidad cero después de la normalización. En implementaciones numéricas se usa un valor negativo muy grande para aproximar ese efecto.

La diagonal suele permitirse porque la representación en la posición i no contiene todavía el target futuro que se quiere predecir en el esquema desplazado. La interpretación exacta depende de cómo se alinean entradas y objetivos, pero la regla general es impedir acceso a información posterior.

2 Máscara triangular

Para una secuencia de longitud T , se define una máscara

$$M_{ij} = \begin{cases} 0, & j \leq i, \\ -\infty, & j > i. \end{cases}$$

Esta ecuación se lee así: las posiciones permitidas no cambian el logit; las posiciones futuras reciben una penalización infinita antes de softmax.

Si $S \in \mathbb{R}^{T \times T}$ es la matriz de scores, los scores enmascarados son

$$\tilde{S} = S + M.$$

Luego se calcula

$$A = \text{softmax}_{\text{fila}}(\tilde{S}).$$

Después de softmax, las entradas futuras tienen peso cero.

3 Distribución causal por fila

Para cada posición i , la distribución cumple

$$A_{ij} = 0 \quad \text{si} \quad j > i, \quad \sum_{j=1}^i A_{ij} = 1.$$


Esta ecuación se lee así: toda la masa de atención de la fila i se reparte entre posiciones permitidas.

La salida sigue siendo

$$Y = AV,$$

pero ahora cada y_i solo mezcla valores del pasado y del presente.

4 Figura conceptual



La figura debe leerse como una matriz triangular de permisos. La diagonal y la región inferior son visibles; la región superior representa futuro bloqueado.

Cómo leer la figura

La figura triangular debe leerse por filas. En cada fila se ve qué columnas están disponibles para una posición que consulta. La región superior bloqueada corresponde a tokens futuros; la región permitida corresponde a pasado y presente representacional.

El interés de la figura no es la forma triangular por sí sola, sino la consecuencia experimental: sin esa máscara, la evaluación de predicción del siguiente token queda contaminada.

5 Límites de interpretación

La máscara causal garantiza disponibilidad correcta de información, no calidad del modelo. Un modelo causal puede repetir, memorizar, generalizar mal o asignar pesos poco interpretables. La causalidad es condición necesaria para entrenamiento autoregresivo, no garantía de comprensión.

La causalidad correcta tampoco evita errores de exposición durante generación. En entrenamiento se condiciona en prefijos reales del corpus; en generación se condiciona cada vez más en tokens producidos por el propio modelo. Esa diferencia puede amplificar errores.

Observación 1 (Pérdida engañosa). Si una implementación permite mirar el futuro, la pérdida puede mejorar por la razón equivocada. Ese resultado no evalúa predicción autoregresiva real.

6 Errores de lectura técnica

Un error habitual es creer que la máscara causal elimina tokens del tensor. No los elimina; modifica los scores antes de softmax para que las posiciones futuras reciban peso cero. Los tensores conservan su forma (T, T) , pero ciertas celdas quedan anuladas en la distribución.

También es importante distinguir máscara causal de padding mask. La máscara causal bloquea futuro por razones autoregresivas. Una máscara de padding bloquea posiciones vacías que no pertenecen al contenido real. En modelos prácticos pueden combinarse, pero responden a problemas distintos.

La diagonal requiere una lectura cuidadosa. En muchas implementaciones se permite atender a la posición actual porque la representación de entrada en esa posición corresponde al token disponible para predecir el siguiente, no a un target futuro. La validez depende de la alineación entre entradas y objetivos.

7 Resumen

Resumen 1 (Cierre de la nota). La atención causal suma una máscara triangular a los scores antes de softmax. Esto fuerza pesos cero sobre posiciones futuras y mantiene la mezcla $Y = AV$ dentro de la información permitida por la factorización autoregresiva.

8 Preguntas de estudio

1. ¿Qué representa la condición $j \leq i$?
2. ¿Por qué se usa $-\infty$ antes de softmax?
3. ¿Qué error produce permitir atención a posiciones futuras?
4. ¿Por qué causalidad correcta no implica buena generación?
5. ¿Cómo cambia la interpretación de una fila de A bajo máscara causal?

9 Continuidad

La atención causal puede ejecutarse en varias cabezas para permitir mezclas paralelas en subespacios distintos.