

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 10

Multi-head attention

Curso abierto

2026-I

Multi-head attention divide canales en subespacios paralelos; no divide la secuencia en varios textos.

1 Motivación técnica

Una sola cabeza calcula una matriz de pesos y una mezcla de valores en un espacio de dimensión D . Multi-head attention replica esta operación en H subespacios para que distintas cabezas puedan aprender patrones de comparación diferentes.

Sea una entrada

$$X \in \mathbb{R}^{B \times T \times C}.$$

Para dividir canales en H cabezas de dimensión D , debe cumplirse

$$C = H \cdot D.$$

Esta ecuación se lee así: cada cabeza recibe una fracción regular del eje de canales.

Idea clave 1 (Canales, no tokens). Las cabezas no separan la secuencia en fragmentos. Todas las cabezas ven las posiciones; lo que se divide es el espacio de representación.

Ampliación conceptual

La intuición de varias cabezas es permitir que distintas proyecciones aprendan criterios de comparación diferentes. Una cabeza podría concentrarse en relaciones cercanas, otra en patrones más dispersos, otra en señales posicionales; pero esas descripciones solo son hipótesis que deben verificarse.

Cuando C se mantiene fijo, aumentar H reduce D . Esto crea un intercambio: más cabezas paralelas, pero menos dimensión por cabeza. No existe un número de cabezas universalmente mejor; depende de escala, datos y objetivo.

La proyección final W_O es importante porque permite mezclar la información producida por las cabezas. Sin ella, las salidas quedarían simplemente concatenadas, con menor interacción entre subespacios.

2 Proyección y reorganización

Las proyecciones producen tensores que luego se reorganizan como

$$(B, T, C) \rightarrow (B, T, H, D) \rightarrow (B, H, T, D).$$

Esta cadena se lee así: primero se separan canales por cabeza; luego se coloca el eje de cabezas antes del tiempo para calcular atención por cabeza en paralelo.

Para cada cabeza h , se calculan

$$S^{(h)} = \frac{Q^{(h)} K^{(h)\top}}{\sqrt{D}}, \quad A^{(h)} = \text{softmax}_{\text{fila}}(S^{(h)}), \quad Y^{(h)} = A^{(h)} V^{(h)}.$$

Cada cabeza produce una salida $Y^{(h)} \in \mathbb{R}^{B \times T \times D}$.

3 Concatenación y proyección final

Las salidas de todas las cabezas se concatenan en el eje de canales:


$$Y_{\text{concat}} = \text{concat}(Y^{(1)}, \dots, Y^{(H)}) \in \mathbb{R}^{B \times T \times C}.$$

Luego una proyección final mezcla información entre cabezas:

$$Y = Y_{\text{concat}} W_O.$$

Esta ecuación se lee así: las cabezas calculan submezclas paralelas y la proyección de salida recompone una representación con la dimensión original.

4 Figura conceptual



La figura muestra división en cabezas, atención paralela, concatenación y proyección. Lo esencial es que la interfaz de entrada y salida conserva (B, T, C) .

5 Costo e interpretación

Aumentar H no crea información nueva por sí mismo. Redistribuye canales entre más cabezas. Si C se mantiene fijo, más cabezas implican menor D por cabeza. Si se aumenta C , suben parámetros y costo.

Una cabeza puede parecer especializada en una visualización aislada y no mantener ese patrón en otros ejemplos. Por eso las afirmaciones sobre especialización de cabezas requieren análisis sistemático, no una sola matriz de atención.

Observación 1 (Cabezas). Comparar mapas de cabezas puede sugerir patrones, pero una cabeza no debe etiquetarse automáticamente como “sintáctica”, “semántica” o “causal” sin evidencia adicional.

6 Errores de lectura técnica

Un error frecuente es suponer que más cabezas siempre significan más capacidad efectiva. Si C se mantiene fijo, aumentar H reduce D . El modelo gana más subespacios paralelos, pero cada subespacio tiene menos canales. La capacidad depende del balance, no solo del número de cabezas.

También se suele creer que cada cabeza aprende una función humana claramente nombrable. En realidad, una cabeza aprende proyecciones y mezclas útiles para la pérdida. Algunas pueden mostrar patrones interpretables, pero esa interpretación debe validarse en múltiples ejemplos.

La concatenación tampoco debe leerse como promedio. Las salidas de las cabezas se colocan una al lado de otra en el eje de canales. La proyección final decide cómo recombinar esos canales y puede mezclar información entre cabezas.

7 Resumen

Resumen 1 (Cierre de la nota). Multi-head attention divide el eje de canales en H subespacios, calcula atención por cabeza, concatena resultados y aplica una proyección final. La condición $C = H \cdot D$ asegura una partición regular de canales.

8 Preguntas de estudio

1. ¿Por qué las cabezas dividen canales y no posiciones?
2. ¿Qué ocurre con D si C se mantiene fijo y aumenta H ?
3. ¿Para qué sirve la proyección final W_O ?
4. ¿Por qué comparar cabezas requiere cautela interpretativa?
5. ¿Qué interfaz conserva multi-head attention?

9 Continuidad

Para construir un bloque decoder apilable, la atención multi-cabeza se combina con residuales, normalización y MLP.