

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 11

Residuales, LayerNorm y MLP

Curso abierto

2026-I

Un bloque Transformer no es solo atención: necesita rutas residuales, normalización y transformación por posición.

1 Tres piezas de estabilidad y capacidad

La atención mezcla información entre posiciones, pero un decoder apilable requiere más componentes. Las conexiones residuales preservan señal y facilitan flujo de gradiente. LayerNorm estabiliza la escala de activaciones. El MLP transforma canales dentro de cada posición.

Sea $X \in \mathbb{R}^{B \times T \times C}$. Una conexión residual tiene la forma

$$Y = X + F(X),$$

donde F es una transformación que conserva la forma. Esta ecuación se lee así: la salida combina la señal original con una modificación aprendida.

Idea clave 1 (Interfaz residual). Para sumar X y $F(X)$, ambos tensores deben tener la misma forma. Por eso muchas subcapas del Transformer devuelven (B, T, C) .

Ampliación conceptual

Las conexiones residuales permiten que una subcapa aprenda una corrección sobre una representación existente en lugar de reconstruir toda la señal desde cero. Esto facilita apilar capas, porque siempre queda disponible un camino directo para información y gradiente.

LayerNorm reduce variaciones de escala dentro de cada posición. En vez de normalizar usando estadísticas del batch, normaliza los canales de un ejemplo y una posición. Esto es especialmente útil en secuencias, donde el tamaño de batch puede cambiar y cada posición debe mantener una escala manejable.

El MLP agrega capacidad no lineal. La atención mezcla posiciones, pero si solo hubiera atención y proyecciones lineales, la transformación por posición sería limitada. El MLP permite transformar combinaciones de canales y crear nuevas características internas.

2 LayerNorm

LayerNorm normaliza canales dentro de cada posición. Para un vector $x \in \mathbb{R}^C$, se define

$$\text{LN}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta,$$

donde μ y σ^2 se calculan sobre los C canales, y $\gamma, \beta \in \mathbb{R}^C$ son parámetros aprendibles. Esta ecuación se lee así: se centra y escala el vector por posición, luego se permite reajustar escala y desplazamiento.

En formulaciones pre-norm, la normalización aparece antes de la subcapa:

$$Y = X + F(\text{LN}(X)).$$

Esto suele mejorar estabilidad al apilar muchos bloques.

3 MLP por posición

El MLP transforma canales de cada posición de manera independiente:


$$\text{MLP}(x) = W_2 \phi(W_1 x + b_1) + b_2.$$

La función ϕ introduce no linealidad. Si W_1 expande de C a rC y W_2 vuelve de rC a C , el MLP aumenta capacidad sin mezclar posiciones directamente.

4 Dropout

Dropout anula aleatoriamente componentes durante entrenamiento. Su función principal es regularizar; no agrega capacidad representacional. En evaluación se desactiva para obtener una salida determinista bajo los mismos parámetros.

5 Figura conceptual



La figura separa las funciones: residual preserva señal, LayerNorm estabiliza activaciones y MLP transforma canales por posición.

Cómo leer la figura

La figura debe leerse como una arquitectura de estabilización. Las rutas residuales rodean subcapas; LayerNorm prepara la entrada de cada transformación; el MLP actúa después de la mezcla atencional para enriquecer cada posición.

La suma residual no debe verse como un detalle visual. Es la razón por la que la entrada original puede persistir incluso si una subcapa aprende una corrección pequeña.

6 Límites de interpretación

Estas piezas hacen entrenable y apilable la arquitectura, pero no garantizan aprendizaje útil. Una red puede ser estable y aun así estar mal entrenada, tener datos pobres o carecer de capacidad suficiente.

La estabilidad arquitectónica no reemplaza el diseño experimental. Un bloque con residuales y normalización puede entrenar de forma más estable, pero aún puede sobreajustar, aprender sesgos o fallar por falta de datos.

Observación 1 (Estabilidad). La normalización reduce problemas de escala, pero no corrige errores de objetivo, datos o evaluación.

7 Errores de lectura técnica

Un error común es considerar las residuales como simples atajos sin efecto conceptual. En realidad, cambian la tarea que aprende cada subcapa: en lugar de producir una representación completa, puede aprender una modificación sobre una representación ya disponible. Esto facilita entrenamiento profundo.

También se confunde LayerNorm con normalización del batch. LayerNorm no usa estadísticas agregadas de varios ejemplos; opera sobre los canales de una posición. Por eso es compatible con generación autoregresiva paso a paso y con tamaños de batch variables.

El MLP por posición tampoco debe entenderse como una capa menor. En muchos Transformers, una fracción importante de los parámetros está en el MLP. Su papel es transformar y expandir características internas después de que la atención haya mezclado información entre posiciones.

8 Resumen

Resumen 1 (Cierre de la nota). Residuales, LayerNorm y MLP convierten la atención en parte de un bloque entrenable. Las residuales conservan forma y señal, LayerNorm estabiliza cada posición y el MLP transforma canales sin mezclar posiciones.

9 Preguntas de estudio

1. ¿Por qué una conexión residual exige conservar forma?
2. ¿Sobre qué eje opera LayerNorm en una representación (B, T, C) ?
3. ¿Por qué el MLP no mezcla posiciones directamente?
4. ¿Qué ventaja conceptual tiene la formulación pre-norm?
5. ¿Por qué dropout no debe interpretarse como aumento de capacidad?

10 Continuidad

Estas piezas se integran con atención causal multi-cabeza para formar un bloque Transformer decoder completo.