

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 12

Bloque Transformer decoder

Curso abierto
2026-I

Un bloque decoder conserva la interfaz tensorial mientras transforma la representación interna de cada posición.

1 Composición del bloque

Un bloque Transformer decoder mínimo combina atención causal multi-cabeza, MLP, normalización y residuales. Su interfaz principal es

$$X \in \mathbb{R}^{B \times T \times C} \quad \mapsto \quad Y \in \mathbb{R}^{B \times T \times C}.$$

Conservar la forma no significa conservar el contenido: la representación cambia, pero sigue siendo compatible con otro bloque apilado.

Idea clave 1 (Apilamiento). La razón por la que los bloques pueden repetirse es que entrada y salida comparten la misma forma (B, T, C) . Cada bloque modifica la representación sin romper la interfaz.

Ampliación conceptual

El bloque decoder es una unidad de composición. Su diseño separa dos tipos de transformación: una entre posiciones, mediante atención causal, y otra dentro de cada posición, mediante MLP. Las residuales conectan ambas con la señal previa.

La formulación pre-norm cambia el lugar donde se normaliza. En lugar de normalizar después de sumar la residual, se normaliza antes de la subcapa. Esta decisión puede mejorar el flujo de gradiente en modelos profundos porque la subcapa recibe activaciones estabilizadas.

Conservar (B, T, C) permite que el bloque se repita L veces. Cada repetición puede construir representaciones más abstractas, pero todas mantienen el mismo contrato de entrada y salida.

2 Formulación pre-norm

Una formulación típica pre-norm es

$$U = X + \text{MHA}(\text{LN}(X)),$$

$$Y = U + \text{MLP}(\text{LN}(U)).$$

La primera ecuación se lee así: se normaliza la entrada, se aplica atención causal multi-cabeza y se suma la señal original. La segunda se lee así: se normaliza la representación intermedia, se transforma por MLP y se suma otra residual.

La cadena operacional puede resumirse como

$$X \rightarrow \text{LN} \rightarrow \text{MHA} \rightarrow U \rightarrow \text{LN} \rightarrow \text{MLP} \rightarrow Y.$$

3 Roles internos


La atención causal mezcla información entre posiciones permitidas. El MLP transforma canales dentro de cada posición. Las residuales preservan caminos de señal. LayerNorm estabiliza escala. Dropout, cuando se usa, regulariza durante entrenamiento.

La máscara causal dentro de MHA mantiene la compatibilidad con la factorización autoregresiva: la representación de la posición t no debe depender de posiciones futuras.

4 Parámetros y costo

El costo del bloque depende de C , T , número de cabezas y factor de expansión del MLP. La atención tiene costo cuadrático en T por los scores (T, T) , mientras el MLP suele concentrar muchos parámetros por sus matrices de expansión y contracción.

5 Figura conceptual



La figura presenta la composición del bloque. Debe leerse como una arquitectura de flujo: normalizar, transformar, sumar residual y repetir.

Cómo leer la figura

La figura debe leerse como un circuito de dos etapas. Primero, la atención causal permite intercambio de información permitido entre posiciones. Segundo, el MLP transforma el contenido de cada posición. Las residuales rodean ambas etapas.

La presencia de dos normalizaciones indica que cada subcapa recibe una versión estabilizada de su entrada. La salida final no es igual a la entrada, aunque conserve forma.

6 Límites de interpretación

Un bloque decoder define capacidad arquitectónica, pero no conocimiento. Antes del entrenamiento, sus salidas son resultado de parámetros iniciales. Después del entrenamiento, su comportamiento depende de datos, objetivo, escala y regularización.

Más bloques no siempre significan mejor modelo en un curso experimental pequeño. Aumentar profundidad aumenta capacidad, pero también costo, sensibilidad a hiperparámetros y riesgo de sobreajuste.

Observación 1 (Forma y contenido). Conservar (B, T, C) es una propiedad de interfaz. No implica que la información interna permanezca igual.

7 Errores de lectura técnica

Un error frecuente es mirar el bloque decoder como una lista de capas independientes. Es mejor leerlo como un circuito: normalización prepara, atención mezcla, residual preserva, normalización vuelve a preparar, MLP transforma y residual vuelve a preservar. El orden importa.

También conviene no confundir el bloque con el modelo completo. El bloque procesa representaciones continuas; no contiene por sí solo la tabla de tokens ni la cabeza de vocabulario. Para formar un modelo de lenguaje se necesita envolverlo con embeddings de entrada y proyección de salida.

La conservación de forma puede ocultar cambios profundos. Dos tensores con forma (B, T, C) pueden representar información muy distinta. La igualdad de forma es una condición de compatibilidad para apilar bloques, no una afirmación sobre el contenido.

8 Resumen

Resumen 1 (Cierre de la nota). El bloque decoder combina atención causal multi-cabeza y MLP mediante normalización y residuales. Su diseño conserva la forma (B, T, C) , permite apilamiento y mantiene la restricción causal necesaria para modelado autoregresivo.

9 Preguntas de estudio

1. ¿Por qué el bloque debe devolver (B, T, C) ?
2. ¿Qué papel cumple la primera residual y qué papel cumple la segunda?
3. ¿Por qué la atención causal mezcla posiciones y el MLP transforma canales?
4. ¿Qué significa pre-norm en las ecuaciones del bloque?
5. ¿Por qué un bloque sin entrenamiento no implica conocimiento lingüístico?

10 Continuidad

Apilando bloques decoder, agregando embeddings iniciales y una cabeza de lenguaje se obtiene un mini-GPT autoregresivo.