

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 13

Mini-GPT desde cero

Curso abierto

2026-I

Un mini-GPT integra embeddings, posiciones, bloques decoder y una cabeza de lenguaje para producir logits sobre el vocabulario.

1 Arquitectura completa mínima

Un modelo de lenguaje autoregresivo mínimo recibe índices

$$X \in \mathbb{N}^{B \times T}$$

y produce logits

$$Z \in \mathbb{R}^{B \times T \times V}.$$

La arquitectura debe convertir llaves discretas en representaciones continuas, procesarlas con bloques causales y proyectarlas al vocabulario.

Idea clave 1 (De ids a logits). La cadena fundamental es: índices, embeddings de token y posición, bloques decoder, normalización final, cabeza de lenguaje y logits.

Ampliación conceptual

Un mini-GPT integra componentes que antes se estudiaron por separado. Los índices entran como datos discretos; los embeddings los transforman en vectores; las posiciones agregan orden; los bloques decoder procesan representaciones causalmente; la cabeza de lenguaje vuelve del espacio de canales al vocabulario.

La cabeza de lenguaje es una proyección por posición. No genera texto directamente; produce un vector de logits. Cada posición tiene su propio vector de puntajes sobre los mismos V tokens posibles. Esta simetría es lo que permite entrenar todas las posiciones de un batch con la misma pérdida.

El número de parámetros se reparte entre tablas de embeddings, bloques y cabeza final. En modelos pequeños, cada decisión de dimensión tiene efectos visibles. Aumentar C , L o V cambia memoria, cómputo y capacidad.

2 Embeddings iniciales

Con una tabla de tokens $E \in \mathbb{R}^{V \times C}$ y una tabla posicional $P \in \mathbb{R}^{T_{\text{máx}} \times C}$, la representación inicial es

$$H_{b,t,:}^{(0)} = E[X_{b,t}] + P_t.$$

Esta ecuación se lee así: cada índice selecciona contenido y cada posición selecciona orden; ambos vectores se suman en $\mathbb{R}^C$.

3 Bloques decoder

Si hay L bloques, la representación evoluciona como

$$H^{(\ell+1)} = \text{Block}_\ell(H^{(\ell)}), \quad \ell = 0, \dots, L-1.$$

Cada bloque conserva la forma (B, T, C) . La profundidad L aumenta capacidad composicional, pero también costo y dificultad de entrenamiento.

Después de los bloques se aplica normalización final:

$$\tilde{H} = \text{LN}(H^{(L)}).$$

4 Cabeza de lenguaje

La cabeza de lenguaje proyecta canales al vocabulario:

$$Z = \tilde{H}W_{\text{vocab}} + b, \quad W_{\text{vocab}} \in \mathbb{R}^{C \times V}.$$

Esta ecuación se lee así: para cada posición, el modelo produce un vector de V puntajes, uno por token candidato.

Los logits no son texto ni probabilidades. Para obtener distribución se aplica softmax en el eje de vocabulario.


5 Pérdida opcional

Si se entregan targets $Y \in \mathbb{N}^{B \times T}$, la pérdida puede calcularse como

$$\mathcal{L}(\theta) = -\frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T \log p_\theta(Y_{b,t} \mid X_{b,\leq t}).$$

Esta ecuación conecta arquitectura con entrenamiento, pero la arquitectura por sí sola no implica aprendizaje.

6 Figura conceptual



La figura muestra la integración: ids, embeddings, bloques, normalización y logits. Es un mapa de flujo arquitectónico, no una prueba de desempeño.

Cómo leer la figura

La figura debe leerse como una cadena de cambios de representación: ids discretos, vectores iniciales, representaciones transformadas, normalización y logits. Cada bloque conserva forma, pero modifica información interna.

El elemento final, `lm_head`, no es una capa decorativa. Es el puente entre la representación interna C y el espacio de decisión sobre V tokens.

7 Límites de interpretación

Un mini-GPT inicializado al azar puede producir logits con la forma correcta. Eso solo verifica la interfaz. Para hablar de comportamiento aprendido se requiere entrenamiento, validación y análisis de generación.

Una prueba con batch sintético verifica que el modelo está cableado correctamente, pero no evalúa lenguaje. Para hablar de aprendizaje se necesita entrenamiento con datos, medición de pérdida y análisis de generación.

Observación 1 (Arquitectura). Una arquitectura correcta define qué puede calcular el modelo; los parámetros entrenados determinan qué efectivamente aprendió bajo un corpus y una pérdida.

8 Resumen

Resumen 1 (Cierre de la nota). El mini-GPT transforma índices (B, T) en logits (B, T, V) mediante embeddings, posiciones, bloques decoder, LayerNorm final y una cabeza de vocabulario. La forma correcta habilita entrenamiento autoregresivo, pero no lo reemplaza.

9 Preguntas de estudio

1. ¿Por qué la salida final debe tener dimensión V ?
2. ¿Qué función cumple la normalización final?
3. ¿Qué cambia al aumentar L , C o el número de cabezas?
4. ¿Por qué logits correctos en forma no prueban aprendizaje?
5. ¿Cómo se conecta esta arquitectura con la pérdida autoregresiva?

10 Continuidad

La arquitectura se vuelve modelo aprendido cuando sus parámetros se ajustan mediante optimización sobre pares entrada-objetivo.