

RECURSO COMPLEMENTARIO

Fundamentos de Transformers

Nota técnica 15

Generación, interpretación y límites

Curso abierto

2026-I

Generar texto es iterar una distribución local; cambiar el muestreo no cambia lo que el modelo aprendió.

1 Inferencia autoregresiva

Durante generación, el modelo recibe un prompt codificado y produce logits para la última posición disponible. A partir de esos logits se obtiene una distribución sobre el vocabulario, se elige un token y se agrega al contexto.

La cadena básica es

$$x_{\leq t} \rightarrow z_t \rightarrow p_{\theta}(\cdot \mid x_{\leq t}) \rightarrow \hat{x}_{t+1} \rightarrow x_{\leq t+1}.$$

Esta ecuación se lee así: el token generado se convierte en parte del contexto para la siguiente predicción.

Idea clave 1 (Muestreo). Las estrategias de generación modifican cómo se elige un token desde una distribución. No actualizan pesos ni corrigen deficiencias del entrenamiento.

Ampliación conceptual

La generación es un proceso cerrado sobre sí mismo. Después del primer token generado, el contexto ya contiene una decisión del modelo. Si esa decisión es mala, las siguientes distribuciones se condicionan en un prefijo degradado. Esta acumulación explica por qué errores pequeños pueden crecer en secuencias largas.

La temperatura modifica la forma de la distribución, no el orden causal ni los parámetros. Top-k y top-p recortan el conjunto de candidatos antes de muestrear. Estas estrategias pueden hacer la salida más conservadora o más diversa, pero no agregan conocimiento que no esté representado en los parámetros.

Greedy decoding suele ser estable pero repetitivo. Sampling puede producir variedad, pero también incoherencia. Por eso la calidad de generación no se evalúa con una sola muestra: requiere comparar configuraciones bajo condiciones controladas.

2 Temperatura

Dado un vector de logits z , la temperatura $\tau > 0$ define

$$p_j(\tau) = \frac{\exp(z_j/\tau)}{\sum_{k=1}^V \exp(z_k/\tau)}.$$

Esta ecuación se lee así: temperaturas bajas hacen más dominante al logit mayor; temperaturas altas suavizan la distribución y aumentan variabilidad.

Con $\tau \rightarrow 0$, el comportamiento se acerca a escoger el token de mayor logit. Con τ grande, la distribución se aplana y aumenta el riesgo de tokens incoherentes.

3 Greedy, top-k y top-p

La generación greedy escoge

$$\hat{x} = \arg \max_j p_j.$$

Es determinista, pero puede volverse repetitiva.

Top-k restringe el soporte a los k tokens con mayor probabilidad y renormaliza. Top-p, o nucleus sampling, conserva el conjunto mínimo de tokens cuya probabilidad acumulada supera un umbral p . Ambos métodos cambian el soporte de muestreo, no los parámetros del modelo.

4 Atención visible y salida

Durante generación pueden observarse mapas de atención. Estos mapas muestran pesos intermedios en ciertas capas y cabezas, pero la decisión final depende de toda la red, la cabeza de lenguaje, la distribución resultante y la regla de muestreo.

5 Figura conceptual



La figura resume el ciclo: prompt, recorte de contexto, logits de última posición, filtros de muestreo, token elegido y actualización del contexto.

Cómo leer la figura

La figura debe leerse como un ciclo, no como una línea que termina. El token elegido se agrega al contexto y vuelve a entrar al modelo. El recorte a longitud máxima indica que el modelo solo conserva una ventana finita de pasado.

Los filtros aparecen después de los logits. Esto significa que no cambian la representación interna ni la pérdida con la que se entrenó el modelo; solo cambian la política de selección durante inferencia.

6 Límites de interpretación

Una salida localmente fluida no prueba comprensión. Puede provenir de patrones frecuentes, repetición, sesgos del corpus o azar controlado por muestreo. Del mismo modo, una mala generación no identifica por sí sola la causa: puede deberse a datos, arquitectura, entrenamiento insuficiente, contexto corto o estrategia de decodificación.

La interpretación de una salida generada debe separar síntoma y causa. Repetición, incoherencia o cambios bruscos son síntomas. La causa puede estar en datos, entrenamiento, arquitectura, longitud de contexto o muestreo. Una sola generación rara vez basta para diagnosticar.

Observación 1 (Control experimental). Para comparar estrategias de muestreo debe fijarse el prompt, el modelo, la semilla cuando aplique y la longitud de generación. Si cambian varias condiciones a la vez, la comparación pierde valor.

7 Resumen

Resumen 1 (Cierre de la nota). La generación autoregresiva itera logits de última posición, softmax, filtros y selección de token. Temperatura, top-k y top-p modifican la distribución usada para muestrear, pero no cambian los parámetros aprendidos ni garantizan comprensión.

8 Preguntas de estudio

1. ¿Por qué durante generación se usan los logits de la última posición?
2. ¿Qué efecto tiene bajar la temperatura?
3. ¿En qué se diferencian top-k y top-p?
4. ¿Por qué cambiar muestreo no corrige un modelo mal entrenado?
5. ¿Por qué atención visible no basta como explicación causal completa?

9 Continuidad

El cierre integrador consiste en reunir datos, arquitectura, entrenamiento, generación, visualización y análisis crítico en un proyecto final reproducible.